Strata 本地大模型 使用说明书

模型：Qwen3.8-Flash-Next IQ3_S ｜ 服务器：http://127.0.0.1:8080 ｜ 部署日期：2026-10-10

一、Strata 是什么

Strata 在你这台电脑上本地运行一个大型语言模型（RTX 5070 Ti 显卡 + 96GB 内存），并对外提供 OpenAI / Anthropic 兼容的 API 接口。所有计算和数据都留在本机，不上传网络。

二、启动与停止

- 启动：双击 `D:\Strata\run-iq3_s.bat`（或 `START-HERE.bat`），会弹出一个黑色窗口开始加载模型。
- 首次加载需要几分钟，期间电脑可能明显变卡甚至短暂无响应，属正常现象，不要关闭窗口。
- 窗口出现“ ready: http://127.0.0.1:8080/v1 ”字样即表示就绪，之后每次启动约 30-90 秒。
- 停止：直接关闭那个黑色窗口即可。不用的时候建议关闭以释放内存。

三、浏览器直接使用

服务器运行时，浏览器打开 `http://127.0.0.1:8080`，包含三个页面：

- Chat：网页聊天界面，可直接对话。
- Monitor：实时监控（显存、内存、token 速度等）。
- About：设置与接口地址说明。

四、接入其他应用（API）

应用类型	地址 / 配置
OpenAI 兼容应用	base URL: http://127.0.0.1:8080/v1，API key 随意填，模型名随意填
Anthropic 兼容应用	http://127.0.0.1:8080/v1/messages
Codex CLI / Responses API	http://127.0.0.1:8080/v1/responses
Claude Code	ANTHROPIC_BASE_URL=http://127.0.0.1:8080；ANTHROPIC_MODEL 填任意 Claude 模型名；ANTHROPIC_AUTH_TOKEN 随意填

思考深度：请求中加 "reasoning_effort": "none" / "low" / "medium" / "high"（默认 high，越低越快）。

五、注意事项

- 服务器只监听 127.0.0.1（仅本机可访问）。如需局域网访问，必须同时设置 --host 0.0.0.0 和 --api-key，切勿裸奔。
- 显卡同时在驱动显示器：若加载模型后出现黑屏或死机，重新运行 setup 并加参数 --vram-reserve-mib 1500。
- 默认一次只处理一个请求。多个应用同时使用会排队；需要并发可重跑 setup 加 --parallel N（每个请求速度损失约 10-25%）。
- 模型数据 85.8GB 在 D:\Strata-data，请勿删除；C 盘空间紧张时也不要移动它。

- 当前配置未开启图片识别（vision）。需要读图可重跑 setup 加 --vision yes。
- 上下文长度 65536 tokens；提示词超长时重跑 setup --setup --context 加大。

六、常见问题排查

现象	处理方法
网页打不开 / 接口无响应	确认服务器窗口开着；等窗口出现 ready 行；或访问 http://127.0.0.1:8080/health 看 loaded 是否为 true
端口 8080 被占用	说明 Strata 已在运行；确实被别的程序占用则重跑 setup 加 --port 8081
非常慢、硬盘狂转	内存不足：关闭其他程序；或换更小量化 --setup --model IQ2_XS
显存不足报错（cudaMalloc failed）	Windows 页面文件被禁用：设为“ 系统管理的大小 ”后重启
提示词超出上下文	重跑 setup --setup --context 加大数值
安装/下载中断	重新运行同一条 setup 命令，会自动续传
引擎意外停止	查看 D:\Strata\strata-iq3_s.log；重启 run-iq3_s.bat

七、关键文件位置

- 程序目录：D:\Strata
- 模型数据：D:\Strata-data（85.8 GB，勿删）
- 启动脚本：D:\Strata\run-iq3_s.bat
- 安装日志：D:\Strata\setup-run.log ｜ 引擎日志：D:\Strata\strata-iq3_s.log
- 官方文档：D:\Strata\docs（INSTALL.md、AI_SETUP.md、TROUBLESHOOTING.md 等）
- 本说明书与安装记录：桌面《本地部署》文件夹

性能参考：本机实测推理速度约 42.5 tokens/s（短回复、无思考模式）。模型完全本地运行，无任何数据离开本机。